

TRƯỜNG ĐẠI HỌC KINH TẾ - LUẬT
KHOA TÀI CHÍNH – NGÂN HÀNG



BÁO CÁO CUỐI KỲ
MÁY HỌC VÀ TRÍ TUỆ NHÂN TẠO TRONG TÀI CHÍNH
DỰ BÁO KIẾT QUỆ TÀI CHÍNH DOANH NGHIỆP NIÊM YẾT
TẠI VIỆT NAM

Giảng viên hướng dẫn: ThS. Phan Huy Tâm

Sinh viên thực hiện: Trần Nguyễn Ánh Tú

Mã số sinh viên: K234141687

Mã lớp học phần: 253BFF402101

Thành phố Hồ Chí Minh, tháng 7 năm 2026

LỜI CẢM ƠN

Trong quá trình thực hiện bài báo cáo học phần Máy học, em đã nhận được sự hướng dẫn và hỗ trợ tận tình từ ThS. Phan Huy Tâm. Em xin chân thành gửi lời cảm ơn Thầy vì đã truyền đạt những kiến thức nền tảng và chuyên sâu về lĩnh vực Máy học, đồng thời tạo điều kiện để sinh viên tiếp cận và vận dụng các thuật toán học máy vào giải quyết những bài toán thực tiễn.

Những bài giảng, sự hướng dẫn và các góp ý của Thầy đã giúp em rèn luyện tư duy phân tích, nâng cao kỹ năng xử lý dữ liệu, xây dựng mô hình và đánh giá kết quả nghiên cứu. Đây không chỉ là nền tảng quan trọng để hoàn thành học phần mà còn là hành trang hữu ích cho quá trình học tập, nghiên cứu và định hướng nghề nghiệp của em trong lĩnh vực phân tích dữ liệu và trí tuệ nhân tạo.

Mặc dù đã dành nhiều thời gian và nỗ lực để hoàn thành bài báo cáo, song do kiến thức và kinh nghiệm thực tế còn hạn chế nên bài làm khó tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến nhận xét và góp ý từ Thầy để em có cơ hội hoàn thiện hơn kiến thức chuyên môn cũng như kỹ năng nghiên cứu của mình.

Một lần nữa, em xin trân trọng cảm ơn Thầy và kính chúc Thầy luôn dồi dào sức khỏe, hạnh phúc và thành công trong công tác giảng dạy, nghiên cứu.

Trân trọng.

MỤC LỤC

LỜI CẢM ƠN	ii
DANH MỤC HÌNH ẢNH	iv
DANH MỤC BẢNG BIỂU	iv
1. GIỚI THIỆU	1
1.1. Bối cảnh nghiên cứu	1
1.2. Động lực nghiên cứu	2
1.3. Khoảng trống nghiên cứu	2
1.4. Mục tiêu nghiên cứu	3
1.5. Câu hỏi nghiên cứu	4
1.6. Đóng góp của đề tài	4
2. DỮ LIỆU NGHIÊN CỨU	5
2.1. Nguồn dữ liệu	5
2.2. Mô tả bộ dữ liệu	6
2.3. Đặc điểm và chất lượng dữ liệu	7
2.4. Đánh giá sự phù hợp của bộ dữ liệu đối với nghiên cứu	8
3. PHƯƠNG PHÁP NGHIÊN CỨU	8
3.1. Xây dựng bài toán dự báo	8
3.2. Thiết kế bài toán theo cơ chế dự báo $t-1 \rightarrow t$	9
3.3. Kiểm toán hiện tượng Data Leakage	10
3.4. Xây dựng bộ dữ liệu sạch (panel $t-1 \rightarrow t$)	11
3.5. Khám phá dữ liệu (Exploratory Data Analysis - EDA)	12
3.6. Chia tập dữ liệu theo thời gian	14
3.7. Tiền xử lý dữ liệu	15
4. KẾT QUẢ THỰC NGHIỆM VÀ SO SÁNH MÔ HÌNH	17
4.1. Thiết lập thực nghiệm	17
4.2. So sánh hiệu quả các mô hình	17
4.3. Đánh giá khả năng phân biệt của mô hình	19
4.4. Lựa chọn mô hình cho các phân tích chuyên sâu	22
5. PHÂN TÍCH CHUYÊN SÂU	22
5.1. Phân tích mức độ quan trọng của biến (Permutation Importance)	22
5.2. Điều chỉnh ngưỡng phân loại (Threshold Tuning)	23
5.4. Phân tích Confusion Matrix của mô hình XGBoost	25
5.5. Hàm ý quản trị	27
6. KẾT LUẬN, HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN	28
6.1. Kết luận	28
6.2. Hạn chế của nghiên cứu	29
6.3. Hướng phát triển trong tương lai	30
TÀI LIỆU THAM KHẢO	31

DANH MỤC HÌNH ẢNH

Hình 3.1: . Phân phối biến mục tiêu và các đặc trưng chính	13
Hình 4.1: So sánh AUC-ROC, Recall, F1 giữa các mô hình.....	19
Hình 4.2: Đường cong ROC — so sánh 7 mô hình.....	20
Hình 4.3: Hình PR Curve	21
Hình 5.1: Top 10 đặc trưng quan trọng nhất — Permutation Importance (Random Forest).....	23
Hình 5.2: Precision–Recall theo ngưỡng quyết định.....	24
Hình 5.3: Confusion Matrix – XGBoost (ngưỡng mặc định vs tối ưu F1).....	27

DANH MỤC BẢNG BIỂU

Bảng 2.1: Tổng quan bộ dữ liệu nghiên cứu	5
Bảng 3.1: Đặc tả bài toán dự báo.....	9
Bảng 3.2: Kiểm toán Data Leakage bằng thực nghiệm.....	10
Bảng 3.3: Các nhóm cột bị loại bỏ khỏi tập đặc trưng và lý do:	11
Bảng 3.4: Top 8 biến lệch phải mạnh nhất (hệ số skewness).....	13
Bảng 3.5: Các cặp biến có tương quan $ r > 0,9$ (sau khi đã loại 2 cặp trùng lặp tuyệt đối)	14
Bảng 3.6: Thống kê tập huấn luyện và tập kiểm định	15
Bảng 3.7: Kết quả GroupKFold Cross-Validation (k = 5, Random Forest, trên tập Train)	17
Bảng 4.1: Kết quả đánh giá trên tập Test (sắp xếp theo AUC-ROC giảm dần)	18
Bảng 5.1: So sánh ngưỡng phân loại — XGBoost (tập Test).....	23
Bảng 5.2: Top 5 biến làm TĂNG nguy cơ kiệt quệ (Odds Ratio > 1).....	24
Bảng 5.3: Top 5 biến làm GIẢM nguy cơ kiệt quệ (Odds Ratio < 1)	25
Bảng 5.4: Ma trận nhầm lẫn ước tính — XGBoost tại ngưỡng tối ưu F1 (0,507).....	26

1. GIỚI THIỆU

1.1. Bối cảnh nghiên cứu

Trong những năm gần đây, thị trường chứng khoán Việt Nam ghi nhận sự gia tăng số lượng doanh nghiệp niêm yết gặp khó khăn về tình hình tài chính. Theo VnEconomy, Sở Giao dịch Chứng khoán TP. Hồ Chí Minh (HOSE) đã công bố danh sách **96 mã chứng khoán không đủ điều kiện giao dịch ký quỹ (margin)** do doanh nghiệp vi phạm các tiêu chí về công bố thông tin, kết quả kinh doanh, ý kiến kiểm toán hoặc các quy định khác của thị trường. Việc bị cắt margin không đồng nghĩa doanh nghiệp đã rơi vào phá sản, nhưng đây là tín hiệu cho thấy sức khỏe tài chính hoặc mức độ minh bạch của doanh nghiệp đang suy giảm, làm gia tăng rủi ro đối với nhà đầu tư và các tổ chức cấp tín dụng. Thực tế này cho thấy nhu cầu nhận diện sớm những doanh nghiệp có nguy cơ gặp khó khăn tài chính ngày càng trở nên cấp thiết.

Đối với ngân hàng và các tổ chức tín dụng, khả năng dự báo sớm doanh nghiệp có nguy cơ kiệt quệ tài chính giúp nâng cao chất lượng thẩm định tín dụng, xây dựng hệ thống cảnh báo sớm (Early Warning System), chủ động giám sát khách hàng và hạn chế phát sinh nợ xấu. Đối với nhà đầu tư, kết quả dự báo hỗ trợ đánh giá rủi ro doanh nghiệp trước khi đưa ra quyết định đầu tư, đồng thời góp phần tối ưu hóa danh mục và giảm thiểu tổn thất từ các doanh nghiệp có dấu hiệu suy giảm tài chính. Về phía doanh nghiệp, việc phát hiện sớm các dấu hiệu bất thường về khả năng thanh khoản, đòn bẩy tài chính và hiệu quả hoạt động tạo điều kiện để điều chỉnh chiến lược kinh doanh, cơ cấu vốn và kế hoạch tài chính trước khi rơi vào tình trạng kiệt quệ nghiêm trọng.

Song song với sự phát triển của dữ liệu tài chính và năng lực tính toán, các phương pháp Machine Learning ngày càng được ứng dụng rộng rãi trong lĩnh vực quản trị rủi ro tài chính nhờ khả năng khai thác đồng thời nhiều chỉ tiêu tài chính và nhận diện các quan hệ phi tuyến mà các mô hình thống kê truyền thống khó mô tả. Tuy nhiên, nhiều nghiên cứu vẫn xây dựng mô hình trên dữ liệu cùng kỳ, tức sử dụng các chỉ tiêu tài chính của năm t để dự báo tình trạng kiệt quệ của chính năm t . Cách tiếp cận này có nguy cơ phát sinh data leakage, đặc biệt khi biến mục tiêu được hình thành từ chính các chỉ tiêu tài chính đang được sử dụng làm biến đầu vào, khiến kết quả đánh giá mô hình trở nên quá lạc quan và khó phản ánh đúng năng lực dự báo trong thực tế.

Xuất phát từ bối cảnh đó, nghiên cứu này xây dựng hệ thống cảnh báo sớm nguy cơ kiệt quệ tài chính cho 533 doanh nghiệp niêm yết Việt Nam giai đoạn 2020–2025 theo thiết kế

$t-1 \rightarrow t$, trong đó các chỉ tiêu tài chính của năm trước được sử dụng để dự báo khả năng doanh nghiệp rơi vào tình trạng kiệt quệ trong năm tiếp theo. Đồng thời, nghiên cứu tiến hành kiểm toán hiện tượng data leakage trước khi xây dựng mô hình và so sánh nhiều thuật toán Machine Learning nhằm đánh giá khả năng ứng dụng của các phương pháp này trong hệ thống cảnh báo sớm rủi ro tài chính tại Việt Nam.

1.2. Động lực nghiên cứu

Dự báo kiệt quệ tài chính là một chủ đề đã được nghiên cứu từ nhiều thập kỷ trước với các mô hình nổi tiếng như Altman Z-score (1968) và Ohlson O-score (1980). Tuy nhiên, phần lớn các mô hình truyền thống được xây dựng dựa trên các giả định tuyến tính, số lượng biến đầu vào hạn chế và chưa tận dụng được khả năng học từ dữ liệu quy mô lớn của các thuật toán Machine Learning hiện đại.

Trong những năm gần đây, nhiều nghiên cứu quốc tế đã chứng minh rằng các thuật toán như Random Forest, XGBoost, Support Vector Machine có thể cải thiện đáng kể khả năng dự báo rủi ro tài chính so với các phương pháp truyền thống. Tuy nhiên, việc áp dụng các mô hình này cho dữ liệu doanh nghiệp Việt Nam vẫn còn tương đối hạn chế do khó khăn trong việc thu thập dữ liệu có chất lượng, thiếu các bộ dữ liệu công khai được chuẩn hóa và sự khác biệt về đặc điểm thị trường.

Bên cạnh những khó khăn về dữ liệu, một vấn đề phương pháp luận quan trọng trong các nghiên cứu dự báo kiệt quệ tài chính là hiện tượng rò rỉ dữ liệu (data leakage). Trong quá trình kiểm toán bộ dữ liệu, nghiên cứu nhận thấy rằng ngay cả khi loại bỏ các biến trực tiếp tạo nên nhãn (signal_*), việc sử dụng các chỉ tiêu tài chính của cùng kỳ vẫn có thể giúp mô hình tái tạo gần như hoàn toàn quy tắc hình thành biến mục tiêu. Thực nghiệm trong nghiên cứu cho thấy mô hình Random Forest đạt AUC xấp xỉ 0,99 trên dữ liệu cùng kỳ mặc dù đã loại bỏ các biến signal_*, chứng tỏ mô hình không thực sự học được khả năng dự báo mà chỉ học lại công thức xây dựng nhãn. Vì vậy, nếu không xử lý hiện tượng này, kết quả đánh giá sẽ quá lạc quan và không phản ánh khả năng ứng dụng trong thực tế.

Xuất phát từ vấn đề trên, nghiên cứu lựa chọn thiết kế bài toán theo cơ chế dự báo $t-1 \rightarrow t$, sử dụng toàn bộ đặc trưng tài chính của năm trước để dự báo nguy cơ kiệt quệ tài chính của năm hiện tại. Đồng thời, nghiên cứu tiến hành kiểm toán rò rỉ dữ liệu trước khi xây dựng mô hình nhằm đảm bảo kết quả đánh giá phản ánh đúng khả năng dự báo của hệ thống cảnh báo sớm.

1.3. Khoảng trống nghiên cứu

Qua tổng quan các nghiên cứu trong và ngoài nước, có thể nhận thấy một số khoảng trống đáng chú ý.

Thứ nhất, phần lớn các nghiên cứu kinh điển về dự báo phá sản doanh nghiệp chủ yếu sử dụng các mô hình thống kê như phân tích biệt số (Discriminant Analysis) hoặc hồi quy Logistic. Các mô hình này có ưu điểm về khả năng diễn giải nhưng còn hạn chế trong việc khai thác các quan hệ phi tuyến giữa nhiều chỉ tiêu tài chính.

Thứ hai, nhiều nghiên cứu Machine Learning hiện nay chủ yếu sử dụng các bộ dữ liệu quốc tế hoặc dữ liệu công khai trên các nền tảng chia sẻ, trong khi dữ liệu doanh nghiệp niêm yết Việt Nam được xây dựng từ báo cáo tài chính gốc vẫn còn tương đối ít.

Thứ ba, nhiều nghiên cứu mới chỉ loại bỏ các biến trực tiếp tạo thành nhãn mà chưa tiến hành kiểm toán rò rỉ dữ liệu bằng thực nghiệm để kiểm chứng liệu các đặc trưng còn lại có tiếp tục chứa thông tin của biến mục tiêu hay không. Điều này có thể dẫn đến hiện tượng mô hình đạt hiệu suất rất cao nhưng không phản ánh đúng khả năng dự báo trong thực tế.

Thứ tư, chưa nhiều nghiên cứu xây dựng bài toán theo cơ chế dự báo lệch thời gian ($t-1 \rightarrow t$) kết hợp với cách chia dữ liệu theo thời gian (time-based split) và kiểm định theo nhóm doanh nghiệp (GroupKFold), trong khi đây là điều kiện cần để mô phỏng đúng hoạt động của một hệ thống cảnh báo sớm.

Từ những khoảng trống trên, đề tài hướng tới xây dựng một mô hình dự báo vừa đảm bảo tính chính xác, vừa đảm bảo khả năng triển khai thực tế thông qua việc sử dụng dữ liệu doanh nghiệp Việt Nam, thiết kế bài toán theo hướng cảnh báo sớm và kết hợp phân tích ý nghĩa kinh tế của các kết quả thu được.

1.4. Mục tiêu nghiên cứu

Mục tiêu tổng quát

Xây dựng và đánh giá hệ thống dự báo sớm nguy cơ kiệt quệ tài chính của các doanh nghiệp niêm yết tại Việt Nam bằng các thuật toán Machine Learning trên cơ sở dữ liệu tài chính công khai.

Mục tiêu cụ thể

Để đạt được mục tiêu trên, đề tài thực hiện các mục tiêu sau:

- Thu thập và xây dựng bộ dữ liệu tài chính của các doanh nghiệp niêm yết tại Việt Nam trong giai đoạn 2020–2025 từ các nguồn dữ liệu công khai và có độ tin cậy cao.
- Thiết kế bộ dữ liệu theo cơ chế dự báo $t-1 \rightarrow t$, đồng thời kiểm tra và loại bỏ các nguồn gây rò rỉ dữ liệu nhằm đảm bảo tính khách quan của mô hình.

- Xây dựng và so sánh hiệu quả của nhiều thuật toán Machine Learning thuộc các nhóm phương pháp khác nhau, bao gồm Logistic Regression, Decision Tree, Random Forest, XGBoost, K-Nearest Neighbors (KNN), Support Vector Machine (SVM) và Naive Bayes.
- Đánh giá mô hình bằng nhiều chỉ tiêu như Accuracy, Precision, Recall, F1-score, AUC-ROC và AUC-PR nhằm phản ánh đầy đủ hiệu quả dự báo trong bối cảnh dữ liệu mất cân bằng.
- Phân tích tầm quan trọng của các biến đầu vào, diễn giải kết quả dưới góc độ tài chính và đề xuất khả năng ứng dụng mô hình trong thực tiễn.

1.5. Câu hỏi nghiên cứu

Để đạt được các mục tiêu trên, đề tài tập trung trả lời các câu hỏi nghiên cứu sau:

- Liệu các chỉ tiêu tài chính của năm trước có đủ khả năng dự báo nguy cơ kiệt quệ tài chính của doanh nghiệp trong năm tiếp theo hay không?
- Thuật toán Machine Learning nào cho hiệu quả dự báo tốt nhất trên dữ liệu doanh nghiệp niêm yết Việt Nam?
- Việc loại bỏ hiện tượng data leakage ảnh hưởng như thế nào đến kết quả đánh giá mô hình?
- Những nhóm chỉ tiêu tài chính nào đóng vai trò quan trọng nhất trong việc dự báo nguy cơ kiệt quệ tài chính?
- Mô hình có thể được ứng dụng như thế nào trong hoạt động quản trị rủi ro của ngân hàng, doanh nghiệp và nhà đầu tư?

1.6. Đóng góp của đề tài

Về mặt dữ liệu, đề tài xây dựng bộ dữ liệu panel gồm các doanh nghiệp niêm yết tại Việt Nam trong giai đoạn 2020–2025 từ các nguồn công khai có độ tin cậy cao như CafeF và Vietstock Finance, đáp ứng yêu cầu về nguồn gốc và tính cập nhật của dữ liệu.

Về mặt phương pháp, nghiên cứu thực hiện kiểm toán hiện tượng data leakage bằng thực nghiệm, chứng minh rằng việc chỉ loại bỏ các biến `signal_*` vẫn chưa loại bỏ hoàn toàn rò rỉ dữ liệu nếu sử dụng đặc trưng cùng kỳ. Trên cơ sở đó, nghiên cứu xây dựng bộ dữ liệu theo cơ chế lệch thời gian ($t-1 \rightarrow t$), kết hợp chia dữ liệu theo thời gian (time-based split) và kiểm tra độ ổn định của mô hình bằng GroupKFold theo từng doanh nghiệp.

Việc so sánh hiệu quả của bảy thuật toán Machine Learning thuộc nhiều nhóm phương pháp khác nhau, nghiên cứu còn thực hiện phân tích Permutation Importance để xác định các

biến tài chính quan trọng, tối ưu ngưỡng phân loại bằng Threshold Tuning, diễn giải hệ số Logistic Regression thông qua Odds Ratio và đánh giá kết quả bằng nhiều chỉ tiêu như AUC-ROC, AUC-PR, Recall và F1-score. Những phân tích này giúp nâng cao khả năng giải thích của mô hình và tăng tính ứng dụng trong xây dựng hệ thống cảnh báo sớm cho doanh nghiệp, ngân hàng và nhà đầu tư.

2. DỮ LIỆU NGHIÊN CỨU

2.1. Nguồn dữ liệu

Chất lượng của bộ dữ liệu đóng vai trò quyết định đối với hiệu quả của các mô hình Machine Learning, đặc biệt trong các bài toán dự báo tài chính. Khác với nhiều nghiên cứu sử dụng các bộ dữ liệu tổng hợp hoặc dữ liệu từ các nền tảng chia sẻ không công bố rõ nguồn gốc, nghiên cứu này xây dựng bộ dữ liệu từ các báo cáo tài chính chính thức của doanh nghiệp niêm yết tại Việt Nam. Việc sử dụng dữ liệu công khai, có nguồn gốc rõ ràng và đã được kiểm toán giúp nâng cao tính tin cậy của kết quả nghiên cứu, đồng thời đáp ứng yêu cầu của học phần về tính minh bạch của dữ liệu.

Bộ dữ liệu được thu thập thủ công từ hai nguồn thông tin tài chính uy tín là CafeF (cafef.vn/du-lieu) và Vietstock Finance (finance.vietstock.vn). Đây là các nền tảng tổng hợp dữ liệu từ báo cáo tài chính, báo cáo thường niên và các thông tin công bố của doanh nghiệp niêm yết trên thị trường chứng khoán Việt Nam. Toàn bộ dữ liệu đều được đối chiếu giữa các nguồn trước khi tích hợp nhằm hạn chế sai lệch trong quá trình thu thập.

Bộ dữ liệu bao gồm các doanh nghiệp đang niêm yết trên hai sở giao dịch chứng khoán lớn nhất Việt Nam là HOSE và HNX, với giai đoạn nghiên cứu từ năm 2020 đến năm 2025. Khoảng thời gian này đáp ứng yêu cầu của môn học về việc sử dụng dữ liệu có độ trễ không quá ba năm tính đến thời điểm thực hiện nghiên cứu, đồng thời phản ánh tương đối đầy đủ các biến động của doanh nghiệp trong giai đoạn hậu đại dịch COVID-19 và quá trình phục hồi của nền kinh tế.

Bảng 0.1: Tổng quan bộ dữ liệu nghiên cứu

Thuộc tính	Chi tiết
Phạm vi	533 doanh nghiệp niêm yết trên HOSE và HNX
Giai đoạn	2020 – 2025 (6 năm, tối đa 6 quan sát/doanh nghiệp)

Thuộc tính	Chi tiết
Nguồn thu thập	CafeF (cafef.vn/du-lieu) và Vietstock Finance (finance.vietstock.vn) - báo cáo tài chính đã kiểm toán/soát xét, công bố công khai, dữ liệu Lầu 8.
Thành phần dữ liệu	(1) Chỉ số vòng đời doanh nghiệp theo mô hình Dickinson (1989); (2) Chỉ tiêu tài chính cơ bản; (3) Tỷ số CAMEL; (4) Thành phần mô hình Beneish M-score
Kích thước panel sạch(sau xử lý, Bước 4)	2.538 quan sát $\times$ 41 cột, tỷ lệ nhân dương 14,7%

Có thể thấy bộ dữ liệu có quy mô đủ lớn để triển khai và đánh giá nhiều thuật toán Machine Learning khác nhau, đồng thời phản ánh đặc điểm của nhiều nhóm ngành trên thị trường chứng khoán Việt Nam.

2.2. Mô tả bộ dữ liệu

Bộ dữ liệu được xây dựng bằng cách tích hợp nhiều nhóm chỉ tiêu tài chính nhằm phản ánh toàn diện tình hình hoạt động của doanh nghiệp. Thay vì chỉ sử dụng các tỷ số tài chính truyền thống, nghiên cứu kết hợp các chỉ tiêu thuộc nhiều khía cạnh khác nhau của doanh nghiệp để tăng khả năng nhận diện rủi ro kiệt quệ tài chính.

Cụ thể, bộ dữ liệu bao gồm bốn nhóm thông tin chính:

- **Nhóm thứ nhất** là các chỉ tiêu phản ánh vòng đời doanh nghiệp (Firm Life Cycle) được xây dựng theo mô hình của Dickinson (1989). Các biến này giúp mô tả doanh nghiệp đang ở giai đoạn hình thành, tăng trưởng, trưởng thành, suy giảm hoặc tái cấu trúc, từ đó phản ánh đặc điểm dòng tiền và xu hướng phát triển trong từng giai đoạn.
- **Nhóm thứ hai** bao gồm các chỉ tiêu tài chính cơ bản được trích xuất trực tiếp từ báo cáo tài chính như tổng tài sản, doanh thu, lợi nhuận, dòng tiền, vốn lưu động và các tỷ số phản ánh khả năng sinh lời cũng như khả năng thanh toán của doanh nghiệp.
- **Nhóm thứ ba** là Nhóm tỷ số tài chính được xây dựng theo các khía cạnh tương đồng với mô hình CAMEL (Capital, Asset Quality, Earnings và Liquidity), nhằm phản ánh tình hình tài chính tổng thể của doanh nghiệp.

- **Nhóm thứ tư** bao gồm các thành phần của mô hình Beneish M-score như DSRI, GMI, AQI, SGI, DEPI, SGAI, TATA và LVGI được thu thập nhằm đánh giá khả năng bổ sung thông tin cho bài toán dự báo trước khi thực hiện bước lựa chọn đặc trưng.

Việc kết hợp nhiều nhóm biến giúp bộ dữ liệu phản ánh cả quy mô doanh nghiệp, khả năng sinh lời, cấu trúc vốn, dòng tiền, thanh khoản và đặc điểm phát triển của doanh nghiệp, tạo điều kiện thuận lợi cho các thuật toán Machine Learning khai thác các mối quan hệ phức tạp giữa các chỉ tiêu tài chính.

Đặc biệt, thay vì sử dụng trực tiếp các chỉ tiêu của năm hiện tại để dự báo tình trạng kiệt quệ của chính năm đó, toàn bộ các biến đầu vào được dịch chuyển về năm trước (lag 1). Như vậy, mỗi quan sát trong bộ dữ liệu biểu diễn mối quan hệ giữa đặc trưng tài chính năm $t-1$ và tình trạng kiệt quệ của doanh nghiệp ở năm t , đúng với mục tiêu xây dựng hệ thống cảnh báo sớm.

2.3. Đặc điểm và chất lượng dữ liệu

Sau quá trình tổng hợp dữ liệu từ nhiều nguồn, bộ dữ liệu ban đầu gồm 3.072 quan sát. Quá trình tiền xử lý sau đó loại bỏ các quan sát không đáp ứng điều kiện xây dựng dữ liệu lệch thời gian ($t-1 \rightarrow t$), đồng thời xử lý các trường hợp thiếu dữ liệu để tạo thành bộ dữ liệu cuối cùng gồm 2.538 quan sát với 41 biến, được sử dụng trong toàn bộ quá trình huấn luyện và đánh giá mô hình.

Một điểm đáng chú ý của bộ dữ liệu là tỷ lệ doanh nghiệp được gán nhãn kiệt quệ tài chính chỉ khoảng 14,7%, trong khi nhóm không kiệt quệ chiếm hơn 85%. Điều này cho thấy đây là một bài toán phân loại mất cân bằng lớp (Imbalanced Classification). Vì vậy, nghiên cứu không chỉ sử dụng Accuracy mà còn đánh giá mô hình thông qua các chỉ số như Precision, Recall, F1-score, AUC-ROC và AUC-PR nhằm phản ánh đầy đủ hơn khả năng nhận diện nhóm doanh nghiệp có nguy cơ kiệt quệ.

Trong quá trình khám phá dữ liệu, nghiên cứu phát hiện 5 quan sát trong tổng số 3.072 quan sát (chiếm khoảng 0,16%) có giá trị doanh thu thuần (Revenue) âm, thuộc ba doanh nghiệp là HQC, LDG và PTC. Về nguyên tắc kế toán, doanh thu thường không mang giá trị âm. Tuy nhiên, sau khi kiểm tra, đây nhiều khả năng là kết quả của các khoản giảm trừ doanh thu vượt doanh thu ghi nhận hoặc các nghiệp vụ hoàn nhập phát sinh trong lĩnh vực bất động sản, chẳng hạn như hủy hợp đồng hoặc hoàn trả tiền đặt cọc (như trường hợp của LDG).

Do số lượng quan sát bất thường rất nhỏ và các giá trị này vẫn phản ánh những khó khăn tài chính thực tế của doanh nghiệp, nghiên cứu không loại bỏ các quan sát này nhằm tránh

làm mất thông tin có giá trị đối với bài toán dự báo kiệt quệ tài chính. Thay vào đó, ở bước tiền xử lý dữ liệu, các biến có phân phối lệch được biến đổi bằng hàm log1p giữ dấu (signed log1p transformation) để đảm bảo xử lý an toàn cả các giá trị âm mà vẫn bảo toàn ý nghĩa kinh tế của dữ liệu. Ngoài ra, toàn bộ dữ liệu đều được kiểm tra các giá trị thiếu, giá trị ngoại lai và sự nhất quán giữa các nguồn dữ liệu trước khi tiến hành xây dựng mô hình.

2.4. Đánh giá sự phù hợp của bộ dữ liệu đối với nghiên cứu

Bộ dữ liệu được sử dụng đáp ứng tốt các yêu cầu của nghiên cứu cả về nguồn gốc, tính minh bạch và khả năng ứng dụng thực tiễn. So với nhiều nghiên cứu trước đây, điểm khác biệt quan trọng của bộ dữ liệu này là được thiết kế theo cơ chế cảnh báo sớm ($t-1 \rightarrow t$). Cách xây dựng này giúp mô hình chỉ sử dụng thông tin đã biết tại thời điểm dự báo, phù hợp với quy trình quản trị rủi ro của ngân hàng, doanh nghiệp và nhà đầu tư. Đồng thời, việc kiểm toán data leakage trước khi huấn luyện giúp hạn chế hiện tượng đánh giá quá lạc quan thường gặp trong các nghiên cứu dự báo tài chính.

Bộ dữ liệu cũng phản ánh tương đối đầy đủ các khía cạnh của sức khỏe tài chính doanh nghiệp thông qua việc kết hợp các nhóm biến về quy mô, khả năng sinh lời, thanh khoản, cấu trúc vốn, dòng tiền và vòng đời doanh nghiệp. Mặc dù tồn tại hiện tượng mất cân bằng lớp và một số giá trị ngoại lệ, đây đều là những đặc điểm phổ biến của dữ liệu tài chính thực tế. Thay vì loại bỏ hoàn toàn, nghiên cứu lựa chọn các phương pháp tiền xử lý và đánh giá mô hình phù hợp nhằm bảo toàn thông tin và nâng cao khả năng triển khai kết quả trong các hệ thống cảnh báo sớm rủi ro tài chính.

3. PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Xây dựng bài toán dự báo

Mục tiêu của nghiên cứu là xây dựng một mô hình Machine Learning có khả năng dự báo sớm nguy cơ kiệt quệ tài chính của doanh nghiệp niêm yết tại Việt Nam dựa trên các chỉ tiêu tài chính trong quá khứ. Xét dưới góc độ học máy, đây là một bài toán phân loại có giám sát (Supervised Binary Classification), trong đó mô hình học mối quan hệ giữa các biến đầu vào và trạng thái tài chính của doanh nghiệp để đưa ra dự báo cho các quan sát mới.

Khác với các bài toán hồi quy dự báo giá trị liên tục, bài toán trong nghiên cứu này chỉ có hai trạng thái đầu ra:

- 0: Doanh nghiệp **không rơi vào tình trạng kiệt quệ tài chính**.
- 1: Doanh nghiệp **có nguy cơ kiệt quệ tài chính**.

Do đó, đầu ra của mô hình là xác suất doanh nghiệp thuộc lớp "kiệt quệ tài chính", từ đó đưa ra quyết định phân loại dựa trên một ngưỡng xác suất xác định.

Bảng 0.2: Đặc tả bài toán dự báo

Thành phần	Mô tả
Loại bài toán	Phân loại nhị phân (binary classification), có giám sát
Biến mục tiêu	label_distress — bằng 1 nếu doanh nghiệp có ≥ 2 trong 4 tín hiệu kiệt quệ (lỗ, dòng tiền HĐKD âm, thiếu vốn lưu động, đòn bẩy cao) trong năm t
Biến dự báo	Toàn bộ chỉ số tài chính của cùng doanh nghiệp tại năm $t-1$ (early-warning — không dùng dữ liệu cùng kỳ)
Đơn vị quan sát	(Doanh nghiệp, năm t) — dữ liệu dạng panel
Quy mô dữ liệu	2.538 quan sát sau tiền xử lý
Đầu ra mô hình	Xác suất doanh nghiệp rơi vào trạng thái kiệt quệ tài chính năm kế tiếp

Trong đó, biến mục tiêu label_distress được xây dựng theo nguyên tắc tổng hợp từ bốn tín hiệu cảnh báo tài chính bao gồm: (1) lợi nhuận sau thuế âm, (2) dòng tiền từ hoạt động kinh doanh âm, (3) thiếu hụt vốn lưu động, (4) đòn bẩy tài chính ở mức cao.

Một doanh nghiệp được gán nhãn kiệt quệ tài chính khi xuất hiện từ hai tín hiệu trở lên trong cùng một năm tài chính. Cách xây dựng nhãn này giúp phản ánh trạng thái suy giảm tài chính một cách toàn diện hơn so với việc chỉ dựa trên một chỉ tiêu đơn lẻ.

3.2. Thiết kế bài toán theo cơ chế dự báo $t-1 \rightarrow t$

Một trong những đóng góp quan trọng nhất của nghiên cứu là thiết kế bài toán theo cơ chế dự báo lệch thời gian (Temporal Prediction), trong đó toàn bộ các đặc trưng tài chính tại năm $t-1$ được sử dụng để dự báo trạng thái kiệt quệ tài chính của doanh nghiệp tại năm t .

Thiết kế này phản ánh đúng quy trình ra quyết định trong thực tế. Tại thời điểm ngân hàng hoặc nhà đầu tư thực hiện đánh giá rủi ro, chỉ có các báo cáo tài chính đã công bố trong quá khứ mới sẵn có. Thông tin của năm hiện tại chưa được biết trước, vì vậy một hệ thống cảnh báo sớm phải đưa ra dự báo dựa trên dữ liệu lịch sử thay vì dữ liệu cùng kỳ.

Nếu sử dụng đồng thời các chỉ tiêu tài chính của năm t để dự báo chính trạng thái tài chính của năm t , mô hình sẽ không còn thực hiện chức năng dự báo mà chỉ tái tạo lại quy tắc

xây dựng nhãn. Điều này dẫn đến hiện tượng Data Leakage, khiến kết quả đánh giá mô hình bị lạc quan giả tạo và không còn giá trị khi triển khai trên dữ liệu thực tế.

Vì vậy, toàn bộ các biến đầu vào trong nghiên cứu đều được dịch chuyển về năm trước thông qua kỹ thuật lag 1, bảo đảm mọi thông tin sử dụng trong quá trình huấn luyện đều xuất hiện trước thời điểm cần dự báo.

3.3. Kiểm toán hiện tượng Data Leakage

Trước khi xây dựng mô hình dự báo, nghiên cứu tiến hành kiểm tra khả năng tồn tại hiện tượng Data Leakage, tức trường hợp thông tin của biến mục tiêu vô tình xuất hiện trong các biến đầu vào. Đây là một trong những nguyên nhân phổ biến khiến mô hình Machine Learning đạt hiệu suất rất cao trên dữ liệu kiểm định nhưng không thể áp dụng trong thực tế.

Trong bộ dữ liệu ban đầu, biến mục tiêu label_distress được xác định dựa trên bốn tín hiệu cảnh báo gồm: signal_NI_neg, signal_CFO_neg, signal_WC_deficit, signal_high_leverage - các tín hiệu này lại được xây dựng trực tiếp từ các chỉ tiêu tài chính của cùng năm như ROA, dòng tiền hoạt động, vốn lưu động và tỷ lệ đòn bẩy.

Điều này đặt ra giả thuyết rằng ngay cả khi loại bỏ các biến signal_* có đủ để có một bài toán dự báo "sạch" hay không, nghiên cứu so sánh AUC-ROC của Random Forest (class_weight)

Bảng 0.3: Kiểm toán Data Leakage bằng thực nghiệm

Kịch bản	AUC-ROC
Dự báo cùng kỳ, giữ toàn bộ biến	1,0000
Dự báo cùng kỳ, loại bỏ signal_*	0,9910
Dự báo lệch thời gian ($t-1 \rightarrow t$), toàn bộ mô hình	0,79 - 0,87 (cao nhất 0,8690 - Random Forest)

Kết quả cho thấy ngay cả sau khi loại bỏ toàn bộ cờ hiệu signal_*, AUC dự báo cùng kỳ vẫn đạt xấp xỉ 0,9910 — gần như hoàn hảo một cách bất thường cho một bài toán tài chính thực tế. Nguyên nhân là các biến "tương như an toàn" còn lại (LEV, ROA, CashRatio...) chính là nguyên liệu đầu vào của công thức tạo nhãn (n_distress_signals là tổng các ngưỡng áp dụng lên những biến này). Loại bỏ cờ hiệu nhưng vẫn giữ dữ liệu cùng kỳ chỉ khiến mô hình "dừng lại" quy tắc gán nhãn, không phải học một quan hệ dự báo thật.

Ngược lại, khi toàn bộ đặc trưng được dịch chuyển về năm trước, AUC giảm xuống khoảng 0,86. Mặc dù thấp hơn đáng kể so với trường hợp dự báo cùng kỳ, kết quả này phản

ánh đúng độ khó của bài toán và thể hiện rằng mô hình đã học được mối quan hệ dự báo thực sự thay vì ghi nhớ quy tắc tạo nhãn. Do đó, toàn bộ các bước xây dựng và đánh giá mô hình trong nghiên cứu đều được thực hiện trên bộ dữ liệu lệch thời gian.

3.4. Xây dựng bộ dữ liệu sạch (panel $t-1 \rightarrow t$)

Trên cơ sở kết quả kiểm toán ở mục 3.3, nghiên cứu loại bỏ khỏi tập đặc trưng các nhóm cột sau, làm giảm số cột từ 56 xuống còn 40 (trước khi thực hiện lag và loại năm đầu mỗi doanh nghiệp):

Bảng 0.4: Các nhóm cột bị loại bỏ khỏi tập đặc trưng và lý do:

Nhóm	Cột	Lý do loại bỏ
Leakage trực tiếp	signal_NI_neg, signal_CFO_neg, signal_WC_deficit, signal_high_leverage, n_distress_signals	Tổng hợp thành công thức tạo ra label_distress
Leakage (trùng lặp)	label	Trùng tuyệt đối với label_distress
Metadata	_src_lifecycle, _src_fundamentals, _src_camel, _src_beneish	Cờ đánh dấu nguồn ghép dữ liệu, không phải chỉ số tài chính
Dư thừa	OCF_sign, ICF_sign, CFF_sign	Đã được mã hoá qua Life_Stage / Stage_*
Dư thừa	price_close	Thay bằng stock_return (đơn vị nhất quán giữa các mã)
Trùng lặp gần tuyệt đối	SIZE_camel	Tương quan $r = 1,00$ với FirmSize_lifecycle — cùng là $\log(\text{tổng tài sản})$, tính hai lần khi ghép 4 nguồn dữ liệu
Trùng lặp gần tuyệt đối	NCF	Tương quan $r = 1,00$ với OCF — chỉ là bản làm tròn của OCF

Sau khi xác định bài toán dự báo và thiết kế cơ chế dự báo lệch thời gian nhằm loại bỏ hiện tượng data leakage, bước tiếp theo là xây dựng bộ dữ liệu phục vụ quá trình huấn luyện và đánh giá mô hình.

Do dữ liệu ban đầu được thu thập theo dạng bảng (panel data), mỗi doanh nghiệp có thể xuất hiện trong nhiều năm liên tiếp. Vì vậy, thay vì coi các quan sát là độc lập hoàn toàn,

nghiên cứu tiến hành sắp xếp dữ liệu theo mã doanh nghiệp (Ticker) và năm tài chính trước khi thực hiện dịch chuyển dữ liệu theo thời gian (lag feature engineering). Các quan sát không đủ thông tin lịch sử (năm đầu tiên của mỗi doanh nghiệp, do không có giá trị lag) bị loại khỏi tập dữ liệu.

Kết quả của quá trình này tạo ra tập dữ liệu cuối cùng gồm 2.538 quan sát và 41 biến, trong đó mỗi quan sát đại diện cho một cặp (*doanh nghiệp, năm*) và phản ánh mối quan hệ giữa tình hình tài chính trong quá khứ với trạng thái kiệt quệ tài chính ở năm kế tiếp.

Việc xây dựng bộ dữ liệu theo nguyên tắc trên giúp mô hình mô phỏng đúng quy trình triển khai trong thực tế, khi các quyết định đánh giá rủi ro luôn được đưa ra dựa trên những thông tin đã biết tại thời điểm phân tích.

3.5. Khám phá dữ liệu (Exploratory Data Analysis - EDA)

Trước khi tiến hành xây dựng mô hình Machine Learning, nghiên cứu thực hiện bước **khám phá dữ liệu (Exploratory Data Analysis - EDA)** nhằm hiểu rõ đặc điểm của bộ dữ liệu, phát hiện các giá trị bất thường, đánh giá mức độ mất cân bằng giữa các lớp và xác định những vấn đề cần xử lý trong giai đoạn tiền xử lý.


3.5.1. Phân bố biến mục tiêu

Phân tích phân bố của biến mục tiêu cho thấy dữ liệu có sự mất cân bằng đáng kể giữa hai lớp. Trong tổng số 2.538 quan sát, nhóm doanh nghiệp không rơi vào trạng thái kiệt quệ tài chính chiếm khoảng 85,3%, trong khi nhóm doanh nghiệp được gán nhãn kiệt quệ chỉ chiếm khoảng 14,7%.

Sự chênh lệch này phản ánh đúng đặc điểm của dữ liệu tài chính trong thực tế, bởi phần lớn doanh nghiệp niêm yết vẫn duy trì hoạt động bình thường và chỉ một tỷ lệ nhỏ gặp khó khăn tài chính nghiêm trọng.

Tuy nhiên, dữ liệu mất cân bằng cũng đặt ra thách thức đối với quá trình huấn luyện mô hình. Nếu chỉ sử dụng chỉ tiêu Accuracy, mô hình có thể đạt kết quả rất cao bằng cách dự đoán tất cả doanh nghiệp đều thuộc lớp không kiệt quệ, nhưng hoàn toàn thất bại trong việc phát hiện nhóm doanh nghiệp có rủi ro.

Do đó, nghiên cứu sử dụng thêm các chỉ số Precision, Recall, F1-score, ROC-AUC và đặc biệt là Precision-Recall AUC để đánh giá toàn diện khả năng dự báo của mô hình.



Hình 0.1: . Phân phối biến mục tiêu và các đặc trưng chính

3.5.2. Phân bố của các biến tài chính

Kết quả khảo sát cho thấy các biến phản ánh quy mô doanh nghiệp tính bằng VNĐ có hiện tượng lệch phải (right-skewed) rất mạnh, với hệ số skewness dao động khoảng 11–16:

Bảng 0.5: Top 8 biến lệch phải mạnh nhất (hệ số skewness)

Biến	Skewness
EBIT_MARGIN_lag1	16,22
current_liabilities_lag1	14,35
interest_expense_lag1	13,63
retained_earnings_lag1	13,56
total_liabilities_lag1	13,21
total_assets_lag1	11,49
income_before_taxes_lag1	11,23
current_assets_lag1	10,84

Sự chênh lệch lớn về quy mô giữa các doanh nghiệp có thể làm giảm hiệu quả học của các thuật toán nhạy cảm với thang đo (Logistic Regression, KNN, SVM), do StandardScaler giả định phân phối gần chuẩn.

3.5.3. Phân tích tương quan giữa các biến

Nghiên cứu tiếp tục đánh giá mức độ tương quan giữa các biến đầu vào thông qua ma trận hệ số tương quan Pearson.

Kết quả cho thấy nhiều nhóm biến có mức độ tương quan tương đối cao, đặc biệt là các chỉ tiêu cùng phản ánh khả năng sinh lời hoặc quy mô doanh nghiệp.

Tuy nhiên, không xuất hiện hiện tượng đa cộng tuyến nghiêm trọng trên phạm vi toàn bộ bộ dữ liệu. Bên cạnh đó, các thuật toán dạng cây như Random Forest và HistGradientBoosting vốn không quá nhạy cảm với tương quan giữa các biến đầu vào. Do đó, nghiên cứu không thực hiện loại bỏ biến chỉ dựa trên hệ số tương quan mà để các thuật toán tự lựa chọn những đặc trưng có giá trị dự báo cao nhất.

Bảng 0.6: Các cặp biến có tương quan $|r| > 0,9$ (sau khi đã loại 2 cặp trùng lặp tuyệt đối)

Cặp biến	Hệ số tương quan (r)
current_liabilities ↔ total_liabilities	0,9831
total_assets ↔ total_liabilities	0,9822
total_assets ↔ current_assets	0,9754
total_assets ↔ current_liabilities	0,9748
current_assets ↔ total_liabilities	0,9645
current_assets ↔ current_liabilities	0,9527

Đây là hiện tượng đa cộng tuyến tự nhiên của báo cáo tài chính (Tổng tài sản $\approx$ Tổng nợ phải trả + Vốn chủ sở hữu), không phải trùng lặp dữ liệu, nên các biến này vẫn được giữ lại vì mỗi biến mang thông tin quy mô/cấu trúc khác nhau. Các mô hình dạng cây (Decision Tree, Random Forest, XGBoost) không nhạy cảm với đa cộng tuyến, nhưng cần lưu ý khi diễn giải riêng lẻ hệ số của Logistic Regression.

3.6. Chia tập dữ liệu theo thời gian

Nghiên cứu chia dữ liệu thành tập huấn luyện và tập kiểm định theo thứ tự thời gian (time-based split) thay vì xáo trộn ngẫu nhiên, nhằm mô phỏng đúng quy trình triển khai của một hệ thống cảnh báo sớm trong thực tế: cụ thể, các quan sát có năm dự báo (Year_target) thuộc giai đoạn 2021–2023 được dùng để huấn luyện, còn các quan sát thuộc giai đoạn 2024–2025 được dành cho kiểm định. Cách tiếp cận này loại bỏ nguy cơ sử dụng thông tin từ tương lai (look-ahead bias).

Bảng 0.7: Thống kê tập huấn luyện và tập kiểm định

Tập dữ liệu	Năm (Year_target)	Kích thước	Tỷ lệ nhãn dương
Train	2021 – 2023	1.504 quan sát × 36 đặc trưng	16,0%
Test	2024 – 2025	1.034 quan sát × 36 đặc trưng	12,9%

Tỷ lệ doanh nghiệp thuộc nhóm kiệt quệ tài chính giữa hai tập không chênh lệch quá lớn, cho thấy quá trình phân chia vẫn duy trì được đặc điểm phân bố của biến mục tiêu.

3.7. Tiền xử lý dữ liệu

Hiệu quả của mô hình Machine Learning phụ thuộc không chỉ vào thuật toán được lựa chọn mà còn vào chất lượng của dữ liệu đầu vào. Vì vậy, trước khi huấn luyện mô hình, bộ dữ liệu được trải qua nhiều bước tiền xử lý nhằm đảm bảo tính ổn định và khả năng học của các thuật toán.

3.7.1. Mã hóa biến phân loại

Biến Life_Stage_lag1 (dạng văn bản, 5 hạng mục: Embryonic, Growth, Maturity, Decline, Shake-out) được mã hóa bằng One-Hot Encoding theo nguyên tắc k-1 **biến giả**, tương ứng với bốn cột **Stage_***, trong khi một nhóm được chọn làm nhóm tham chiếu (reference category), trong khi nhóm Growth được chọn làm hạng mục tham chiếu (khi cả bốn cột dummy đều bằng 0). Cách mã hoá này tránh hiện tượng đa cộng tuyến hoàn hảo (dummy variable trap) đối với Logistic Regression.

3.7.2. Biến đổi dữ liệu (Signed Log1p Transformation)

Để giảm mức độ lệch của các biến quy mô tuyệt đối mà vẫn xử lý an toàn các giá trị âm, nghiên cứu áp dụng phép biến đổi giữ dấu:

$$\mathbf{x}' = \text{sign}(\mathbf{x}) \times \log(1 + |\mathbf{x}|)$$

Phép biến đổi này chỉ được áp dụng cho nhánh dữ liệu phục vụ Logistic Regression, KNN và SVM (các mô hình nhạy cảm với thang đo); Decision Tree, Random Forest và XGBoost được huấn luyện trực tiếp trên dữ liệu gốc chưa biến đổi vì các thuật toán dạng cây chỉ quan tâm đến thứ tự giá trị và bất biến với các phép biến đổi đơn điệu. Đáng chú ý, thực nghiệm cho thấy log-transform không làm tăng đáng kể AUC-ROC (chênh lệch nằm trong khoảng nhiễu ngẫu nhiên) vì các biến tỷ số (ROA, LEV, QUICK_RATIO...) vốn đã đóng góp phần lớn tín hiệu dự báo; tuy nhiên bước này vẫn cần thiết về mặt phương pháp luận để hệ số hồi quy Logistic không bị vài quan sát ngoại lai quy mô lớn chi phối phương sai khi chuẩn hoá.

3.7.3. Xử lý giá trị thiếu

Giá trị thiếu trong dữ liệu tập trung chủ yếu ở biến `stock_return_lag1` (522 quan sát, tương ứng với năm đầu tiên của mỗi mã cổ phiếu — chưa có giá đóng cửa năm trước để tính lợi suất). Các giá trị thiếu được xử lý bằng Median Imputation (`SimpleImputer`, `strategy='median'`): trung vị được tính chỉ trên tập huấn luyện rồi áp dụng cho cả tập huấn luyện và tập kiểm định, nhằm tránh rò rỉ thông tin (data leakage) từ tập kiểm định vào quá trình huấn luyện. So với giá trị trung bình, trung vị ít chịu ảnh hưởng của các giá trị ngoại lai và phù hợp hơn với dữ liệu tài chính có phân phối lệch.

3.7.4. Chuẩn hóa dữ liệu

Đối với các thuật toán dựa trên khoảng cách hoặc tối ưu hóa tuyến tính như Logistic Regression, Support Vector Machine (SVM), K-Nearest Neighbors (KNN) và Naive Bayes, các biến liên tục được chuẩn hóa bằng `StandardScaler` sau khi thực hiện phép biến đổi log. Việc chuẩn hóa giúp các biến có cùng thang đo, cải thiện tốc độ hội tụ và nâng cao hiệu quả dự báo.

Ngược lại, các mô hình dựa trên cây quyết định như Decision Tree, Random Forest và XGBoost không yêu cầu chuẩn hóa dữ liệu. Các thuật toán này chỉ quan tâm đến thứ tự phân chia của các giá trị và gần như bất biến đối với các phép biến đổi đơn điệu, do đó được huấn luyện trực tiếp trên dữ liệu chưa chuẩn hóa.

3.7.5. Xử lý mất cân bằng lớp

Thay vì áp dụng các kỹ thuật lấy mẫu lại (`oversampling/undersampling`) có thể làm sai lệch phân phối gốc của dữ liệu, nghiên cứu xử lý mất cân bằng lớp trực tiếp trong quá trình huấn luyện thông qua tham số `class_weight='balanced'` đối với Logistic Regression, Decision Tree, Random Forest và SVM, và tham số `scale_pos_weight` (tỷ lệ giữa số quan sát âm và số quan sát dương trên tập huấn luyện) đối với XGBoost. Cách tiếp cận này giúp mô hình gán trọng số lớn hơn cho các quan sát thuộc lớp thiểu số (doanh nghiệp kiệt quệ) trong hàm mất mát mà không làm thay đổi số lượng hoặc nội dung quan sát thực tế.

3.8. Kiểm định độ ổn định (GroupKFold Cross-Validation)

Để đánh giá khả năng tổng quát hóa của mô hình và kiểm tra nguy cơ mô hình chỉ ghi nhớ đặc điểm riêng của từng doanh nghiệp, nghiên cứu bổ sung một bước kiểm định độ ổn định bằng Group K-Fold Cross-Validation ($k = 5$) trên tập huấn luyện, sử dụng Random Forest (`n_estimators = 300`, `max_depth = 8`, `class_weight = 'balanced'`). Khác với K-Fold thông thường, phương pháp này phân chia dữ liệu theo nhóm mã cổ phiếu (Ticker), đảm bảo các

quan sát của cùng một doanh nghiệp không xuất hiện đồng thời ở fold huấn luyện và fold kiểm định.

Bảng 0.8: Kết quả GroupKFold Cross-Validation ($k = 5$, Random Forest, trên tập Train)

Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Trung bình	Độ lệch chuẩn
0,8588	0,8515	0,87843	0,861	0,826	0,8363	0,0288

Kết quả cho thấy AUC-ROC trung bình qua 5 fold đạt 0,8363 với độ lệch chuẩn chỉ 0,0288, dao động trong khoảng 0,826–0,8588. Mức độ ổn định này khớp với AUC-ROC trên tập test độc lập (Chương 4, Random Forest đạt 0,8690) và độ lệch chuẩn nhỏ giữa các fold cho thấy mô hình không phụ thuộc quá mức vào việc "ghi nhớ" đặc điểm riêng của một số mã cổ phiếu cụ thể trong tập huấn luyện, mà học được các quy luật tài chính chung có thể áp dụng cho các doanh nghiệp khác.

4. KẾT QUẢ THỰC NGHIỆM VÀ SO SÁNH MÔ HÌNH

4.1. Thiết lập thực nghiệm

Sau khi hoàn thành quá trình tiền xử lý dữ liệu, nghiên cứu tiến hành huấn luyện và đánh giá bảy thuật toán Machine Learning gồm Logistic Regression, Decision Tree, Random Forest, XGBoost (boosting), K-Nearest Neighbors (KNN), Support Vector Machine (SVM) và Gaussian Naive Bayes. Toàn bộ mô hình được huấn luyện trên cùng tập Train (1.504 quan sát, 2021–2023) và đánh giá trên cùng tập Test độc lập (1.034 quan sát, 2024–2025).

Do bài toán dự báo kiệt quệ tài chính có đặc điểm mất cân bằng lớp, nghiên cứu không sử dụng duy nhất chỉ số Accuracy để đánh giá mô hình. Thay vào đó, nhiều thước đo được kết hợp nhằm phản ánh toàn diện hiệu quả dự báo, bao gồm:

- **Accuracy:** tỷ lệ dự báo đúng trên toàn bộ tập kiểm định.
- **Precision:** khả năng hạn chế các cảnh báo sai (False Positive).
- **Recall:** khả năng phát hiện đúng các doanh nghiệp thực sự có nguy cơ kiệt quệ tài chính.
- **F1-score:** trung bình điều hòa giữa Precision và Recall.
- **ROC-AUC:** khả năng phân biệt giữa hai lớp trên nhiều ngưỡng phân loại.
- **PR-AUC:** khả năng phát hiện lớp thiểu số trong bối cảnh dữ liệu mất cân bằng.

Trong bài toán cảnh báo sớm rủi ro tài chính, Recall và PR-AUC được xem là hai chỉ số quan trọng nhất vì mục tiêu ưu tiên là giảm thiểu khả năng bỏ sót doanh nghiệp có nguy cơ kiệt quệ.

4.2. So sánh hiệu quả các mô hình

Bảng 0.9: Kết quả đánh giá trên tập Test (sắp xếp theo AUC-ROC giảm dần)

Mô hình	AUC-ROC	AUC-PR	Accuracy	Precision	Recall	F1
Random Forest	0,8690	0,4309	0,8617	0,4699	0,5865	0,5217
Logistic Regression	0,8660	0,4450	0,7544	0,3256	0,8496	0,4708
SVM (RBF)	0,8619	0,4158	0,7485	0,3116	0,7895	0,4468
XGBoost	0,8530	0,4078	0,8569	0,4599	0,6466	0,5375
Decision Tree	0,8434	0,3972	0,7863	0,3523	0,7895	0,14872
KNN (k=29)	0,8267	0,3678	0,8704	0,3333	0,0075	0,0147
Gaussian Naive Bayes	0,7982	0,3555	0,7756	0,3146	0,6316	0,4200


Kết quả thực nghiệm cho thấy cả bảy mô hình đều đạt khả năng dự báo tốt hơn đáng kể so với ngẫu nhiên, với giá trị AUC-ROC dao động từ 0,7982 đến 0,8690. Điều này chứng tỏ các chỉ tiêu tài chính của năm trước vẫn chứa nhiều thông tin hữu ích để nhận diện nguy cơ kiệt quệ tài chính của doanh nghiệp trong năm tiếp theo, ngay cả khi bài toán được thiết kế theo cơ chế dự báo sớm $t-1 \rightarrow t$.

Xét theo AUC-ROC, Random Forest đạt kết quả cao nhất (0,8690), tiếp theo là Logistic Regression (0,8660), SVM (0,8619) và XGBoost (0,8530). Khoảng cách giữa bốn mô hình này tương đối nhỏ, cho thấy cả mô hình tuyến tính và các mô hình phi tuyến đều có khả năng khai thác hiệu quả các tín hiệu tài chính. Điều này phản ánh rằng dữ liệu không chỉ chứa các quan hệ phi tuyến mà vẫn tồn tại những xu hướng tuyến tính đủ rõ để Logistic Regression đạt hiệu suất cạnh tranh với các thuật toán hiện đại hơn.

Đối với bài toán mất cân bằng lớp, AUC-PR là chỉ số phản ánh tốt hơn khả năng phát hiện doanh nghiệp kiệt quệ. Logistic Regression đạt giá trị AUC-PR cao nhất (0,4450), theo sau là Random Forest (0,4309) và SVM (0,4158). Kết quả này cho thấy Logistic Regression có khả năng duy trì hiệu quả nhận diện lớp thiểu số trên nhiều ngưỡng phân loại, mặc dù phải đánh đổi bằng tỷ lệ cảnh báo sai cao hơn.

Khi xem xét đồng thời Precision, Recall và F1-score, sự khác biệt giữa các mô hình trở nên rõ nét hơn. Logistic Regression đạt Recall cao nhất (0,8496), tiếp theo là SVM (0,7895), chứng tỏ hai mô hình này có khả năng phát hiện phần lớn doanh nghiệp có nguy cơ kiệt quệ.

Tuy nhiên, Precision của cả hai chỉ ở mức khoảng 0,32, cho thấy số lượng cảnh báo sai tương đối lớn. Ngược lại, Random Forest và XGBoost đạt sự cân bằng tốt hơn giữa Precision và Recall, trong đó XGBoost có F1-score cao nhất (0,5375), còn Random Forest đạt AUC-ROC cao nhất. Điều này cho thấy hai mô hình này phù hợp hơn khi mục tiêu là tối ưu hiệu quả dự báo tổng thể.



Hình 0.2: So sánh AUC-ROC, Recall, F1 giữa các mô hình


Một trường hợp đáng chú ý là KNN ($k = 29$) đạt Accuracy rất cao (0,8267) nhưng Recall chỉ 0,0075 — gần như không phát hiện được doanh nghiệp rủi ro, cho thấy mô hình chịu ảnh hưởng nặng bởi mất cân bằng lớp và "lười" dự đoán lớp thiểu số. Đây là minh chứng rõ ràng cho lý do Accuracy không phải là chỉ số phù hợp trong bài toán này. Decision Tree đơn và Naive Bayes có AUC-ROC thấp nhất, do hạn chế tương ứng là dễ overfit/kém khái quát hoá (Decision Tree) và vi phạm giả định độc lập giữa các biến trong khi các chỉ tiêu tài chính vốn tương quan cao (Naive Bayes).

So với mức AUC-ROC gần 1,00 trong thử nghiệm dự báo cùng kỳ, hiệu suất giảm xuống còn 0,79–0,87 sau khi áp dụng thiết kế lệch một kỳ. Sự sụt giảm này là hợp lý và mang tính minh bạch phương pháp luận: mô hình không còn được tiếp cận thông tin xảy ra đồng thời với thời điểm gán nhãn, qua đó loại bỏ hiện tượng rò rỉ dữ liệu. Mức AUC-ROC 0,79–0,87 vẫn cao hơn đáng kể so với mức ngẫu nhiên (0,50), cho thấy các mô hình học được tín hiệu cảnh báo sớm thực sự từ các chỉ tiêu tài chính của năm trước.

4.3. Đánh giá khả năng phân biệt của mô hình

4.3.1. Đường cong ROC

Đường cong ROC (Receiver Operating Characteristic Curve) phản ánh khả năng phân biệt giữa hai nhóm doanh nghiệp kiệt quệ và không kiệt quệ thông qua mối quan hệ giữa tỷ lệ phát hiện đúng doanh nghiệp rủi ro (True Positive Rate) và tỷ lệ cảnh báo sai (False Positive Rate) khi thay đổi ngưỡng phân loại.



Hình 0.3: Đường cong ROC — so sánh 7 mô hình

Kết quả cho thấy bốn mô hình gồm Random Forest, Logistic Regression, SVM (RBF) và XGBoost có đường cong ROC nằm gần nhau, với giá trị AUC-ROC dao động từ 0,8530 đến 0,8690. Trong đó, Random Forest đạt AUC-ROC cao nhất (0,8690), tiếp theo là Logistic Regression (0,8660), SVM (RBF) (0,8619) và XGBoost (0,8530). Chênh lệch giữa các mô hình này không lớn, cho thấy cả mô hình tuyến tính và các mô hình phi tuyến đều có khả năng khai thác hiệu quả thông tin từ dữ liệu tài chính để dự báo nguy cơ kiệt quệ.

Kết quả trên cho thấy các chỉ tiêu tài chính được sử dụng trong nghiên cứu chứa những tín hiệu dự báo có tính ổn định, bao gồm: khả năng sinh lời của doanh nghiệp; mức độ đòn bẩy tài chính; khả năng thanh khoản và vốn lưu động; hiệu quả hoạt động và chất lượng dòng tiền.

Những đặc trưng này có mối liên hệ tương đối rõ với nguy cơ kiệt quệ tài chính, nhờ đó cả các mô hình tuyến tính và phi tuyến đều có thể nhận diện và xây dựng quy luật dự báo.


Đáng chú ý, Logistic Regression – mặc dù là mô hình tuyến tính đơn giản – vẫn đạt AUC-ROC 0,8660, chỉ thấp hơn Random Forest khoảng 0,003 điểm. Kết quả này cho thấy phần lớn tín hiệu dự báo trong bộ dữ liệu có thể được mô hình hóa thông qua các quan hệ tương đối ổn định giữa các chỉ tiêu tài chính và xác suất kiệt quệ, trong khi các mô hình phi tuyến chủ yếu mang lại lợi thế ở việc khai thác các tương tác phức tạp giữa các biến.

Ngược lại, KNN, Gaussian Naive Bayes và Decision Tree có hiệu suất thấp hơn, với AUC-ROC chỉ đạt khoảng 0,8-0,84. Sự khác biệt này có thể được giải thích bởi đặc điểm của từng thuật toán cũng như tính chất của dữ liệu tài chính.

Mặc dù giá trị AUC-ROC của các mô hình thấp hơn so với thử nghiệm sử dụng dữ liệu cùng kỳ, kết quả này phản ánh đúng bối cảnh dự báo thực tế sau khi áp dụng cơ chế $t-1 \rightarrow t$ và loại bỏ hiện tượng data leakage. Việc các mô hình vẫn duy trì AUC-ROC trên 0,85 đối với nhóm mô hình dẫn đầu cho thấy các chỉ tiêu tài chính của năm trước vẫn chứa thông tin có giá trị trong việc xây dựng hệ thống cảnh báo sớm nguy cơ kiệt quệ tài chính của doanh nghiệp.

4.3.2. Đường cong Precision–Recall

Trong các bài toán phân loại có dữ liệu mất cân bằng, ROC Curve đôi khi có thể đưa ra đánh giá tương đối lạc quan do số lượng lớn quan sát thuộc lớp không kiệt quệ làm giảm ảnh hưởng của các trường hợp False Positive. Vì vậy, bên cạnh ROC Curve, nghiên cứu sử dụng thêm Precision–Recall Curve (PR Curve) nhằm đánh giá chính xác hơn khả năng nhận diện các doanh nghiệp có nguy cơ kiệt quệ tài chính.



Hình 0.4: Hình PR Curve

Kết quả cho thấy thứ hạng các mô hình có sự thay đổi khi đánh giá bằng AUC-PR. Logistic Regression đạt giá trị cao nhất (0,4450), tiếp theo là Random Forest (0,4309), SVM (0,4158) và XGBoost (0,4078). Điều này cho thấy mô hình có AUC-ROC cao nhất chưa chắc đã phát hiện tốt nhất nhóm doanh nghiệp có nguy cơ kiệt quệ.

Đối với bài toán cảnh báo sớm, việc bỏ sót doanh nghiệp rủi ro thường gây hậu quả nghiêm trọng hơn so với việc đưa ra một số cảnh báo sai. Vì vậy, Precision và Recall cần được xem xét đồng thời thay vì chỉ dựa vào Accuracy hoặc ROC-AUC.

Kết quả cũng cho thấy Logistic Regression đạt Recall cao nhất (0,8496) nhưng Precision còn thấp (0,3256), trong khi Random Forest và XGBoost duy trì sự cân bằng tốt hơn giữa hai

chỉ số này. Đặc biệt, XGBoost đạt F1-score cao nhất (0,5375), phản ánh khả năng cân bằng giữa việc phát hiện doanh nghiệp rủi ro và hạn chế cảnh báo sai.

Nhìn chung, phân tích PR Curve cho thấy Logistic Regression phù hợp khi ưu tiên phát hiện tối đa doanh nghiệp có nguy cơ, còn Random Forest và XGBoost phù hợp hơn khi cần cân bằng giữa hiệu quả phát hiện và độ chính xác của cảnh báo.

4.4. Lựa chọn mô hình cho các phân tích chuyên sâu

Kết quả thực nghiệm cho thấy không có mô hình nào vượt trội trên tất cả các tiêu chí đánh giá. Mỗi thuật toán đều có những ưu điểm riêng tùy theo mục tiêu sử dụng.


Vì không có mô hình vượt trội tuyệt đối, việc lựa chọn mô hình phù hợp phụ thuộc vào mục tiêu sử dụng thực tế. Nhóm Ensemble/Boosting (Random Forest, XGBoost) cùng với Logistic Regression và SVM cho AUC-ROC cao và ổn định nhất (0,85–0,87). Nếu ưu tiên xếp hạng rủi ro tổng thể, Random Forest là lựa chọn phù hợp nhờ AUC-ROC cao nhất; nếu ưu tiên cân bằng giữa phát hiện đúng và hạn chế cảnh báo sai, XGBoost có F1-score cao nhất và Accuracy tốt trong nhóm dẫn đầu (0,8569); nếu ưu tiên tuyệt đối việc không bỏ sót doanh nghiệp rủi ro, Logistic Regression hoặc SVM phù hợp hơn nhờ Recall cao.

Trên cơ sở F1-score cao nhất và khả năng xử lý trực tiếp giá trị thiếu, nghiên cứu chọn XGBoost làm mô hình đại diện để thực hiện Threshold Tuning và phân tích sai số ở Chương 5, trong khi Random Forest - với kiến trúc bagging đơn giản, ổn định và ít nhạy với siêu tham số - được dùng cho phân tích Permutation Importance nhằm xác định các biến tài chính quan trọng nhất; Logistic Regression được dùng để diễn giải chiều hướng tác động thông qua Odds Ratio.

5. PHÂN TÍCH CHUYÊN SÂU

5.1. Phân tích mức độ quan trọng của biến (Permutation Importance)

Phương pháp Permutation Importance được thực hiện trên mô hình Random Forest và tập kiểm định (20 lần lặp xáo trộn cho mỗi biến, thang đo AUC-ROC), trong đó từng biến được xáo trộn ngẫu nhiên và đo lường mức suy giảm của AUC-ROC. Biến nào làm giảm AUC nhiều hơn khi bị xáo trộn được xem là có vai trò quan trọng hơn trong dự báo



Hình 0.5: Top 10 đặc trưng quan trọng nhất — Permutation Importance (Random Forest)

Kết quả cho thấy một phát hiện đáng chú ý: tỷ lệ nợ trên tổng tài sản (DebtToAssets_lag1) chi phối gần như tuyệt đối khả năng dự báo của mô hình, với mức giảm AUC-ROC (0,0899) cao hơn tổng của toàn bộ 9 biến còn lại trong top 10 cộng lại (Khoảng 0,0264). Các biến còn lại trong top 10 - khả năng thanh khoản (QUICK_RATIO_lag1, CashRatio_lag1), lợi nhuận giữ lại trên tổng tài sản (RE_TA_lag1), đòn bẩy tổng thể (LEV_lag1), lợi nhuận trước thuế, số lượng cổ phiếu lưu hành, tổng nợ phải trả và doanh thu - đóng góp mức giảm AUC-ROC tương đối nhỏ và khá đồng đều với nhau.

Phát hiện này phù hợp với lý thuyết tài chính doanh nghiệp: đòn bẩy tài chính cao là tín hiệu dự báo rủi ro kiệt quệ mạnh nhất, trong khi khả năng sinh lời và thanh khoản đóng vai trò hỗ trợ. Tuy nhiên, việc một biến duy nhất chi phối gần như tuyệt đối cũng là một điểm cần lưu ý: mô hình có thể phụ thuộc khá nhiều vào tín hiệu đòn bẩy khi nhận diện rủi ro.


5.2. Điều chỉnh ngưỡng phân loại (Threshold Tuning)

Trong bài toán cảnh báo sớm, ngưỡng phân loại mặc định 0,5 không nhất thiết là lựa chọn tối ưu, vì chi phí bỏ sót doanh nghiệp có nguy cơ rủi ro (False Negative) thường lớn hơn chi phí cảnh báo nhầm (False Positive). Nghiên cứu khảo sát đường cong Precision–Recall theo ngưỡng của mô hình XGBoost và xác định ngưỡng tối ưu hoá F1-score.

Bảng 0.10: So sánh ngưỡng phân loại — XGBoost (tập Test)

Ngưỡng	Precision	Recall	F1	Số DN kiệt quệ bị bỏ sót (FN)
Mặc định (0,50)	0,460	0,647	—	47

Tối ưu F1 (0,507)	0,465	0,647	0,541	47
-------------------	-------	-------	-------	----



Hình 0.6: Precision–Recall theo ngưỡng quyết định

Kết quả cho thấy ngưỡng tối ưu F1 (0,507) rất gần với ngưỡng mặc định (0,5), do đó Recall và số doanh nghiệp bị bỏ sót (47/133 doanh nghiệp kiệt quệ thực sự trong tập Test, tương ứng Recall $\approx 0,647$) không thay đổi giữa hai ngưỡng; chỉ có Precision cải thiện nhẹ (từ 0,460 lên 0,465), giúp F1-score đạt 0,541. Điều này cho thấy đối với riêng mô hình XGBoost trên bộ dữ liệu này, ngưỡng mặc định 0,5 đã tương đối gần với điểm cân bằng tối ưu giữa Precision và Recall.

Trong triển khai thực tế, nếu ngân hàng hoặc nhà đầu tư ưu tiên tuyệt đối việc không bỏ sót doanh nghiệp sắp kiệt quệ (chi phí bỏ sót — nợ xấu, mất vốn — cao hơn chi phí cảnh báo giả), có thể cân nhắc hạ ngưỡng xuống thấp hơn 0,507, chấp nhận đánh đổi bằng nhiều cảnh báo giả hơn (Precision giảm); ngược lại nếu muốn hạn chế số lượng cảnh báo sai, có thể chọn ngưỡng cao hơn.

5.3. Diễn giải kinh tế thông qua Odds Ratio

Bên cạnh các mô hình phi tuyến, Logistic Regression được sử dụng để giải thích chiều hướng tác động của các biến tài chính thông qua Odds Ratio. Kết quả cho thấy nhóm biến phản ánh mức độ sử dụng nợ có xu hướng làm gia tăng nguy cơ kiệt quệ tài chính, trong khi các biến phản ánh khả năng sinh lời và năng lực tài chính có tác động ngược lại.

Bảng 0.11: Top 5 biến làm TĂNG nguy cơ kiệt quệ (Odds Ratio > 1)

Biến	Hệ số (coef)	Odds Ratio
------	--------------	------------

DebtToAssets_lag1	1,672	5,324
current_liabilities_lag1	1,161	3,194
total_assets_lag1	1,050	2,859
FirmSize_lifecycle_lag1	1,050	2,859
QUICK_RATIO_lag1	0,373	1,451

Bảng 0.12: Top 5 biến làm GIẢM nguy cơ kiệt quệ (Odds Ratio < 1)

Biến	Hệ số (coef)	Odds Ratio
current_assets_lag1	-0,337	0,714
revenue_lag1	-0,410	0,663
ROA_lag1	-0,447	0,640
GROSS_MARGIN_lag1	-0,457	0,633
total_liabilities_lag1	-2,575	0,076

DebtToAssets_lag1 và current_liabilities_lag1 làm tăng nguy cơ rõ rệt nhất — đúng lý thuyết tài chính doanh nghiệp về áp lực đòn bẩy và nợ ngắn hạn. Ngược lại, revenue_lag1, ROA_lag1 và GROSS_MARGIN_lag1 làm giảm nguy cơ, phản ánh vai trò của khả năng sinh lời và hiệu quả hoạt động trong việc duy trì sức khỏe tài chính doanh nghiệp.

Tuy nhiên, kết quả cũng bộc lộ hai điểm cần diễn giải thận trọng. Thứ nhất, QUICK_RATIO_lag1 (một chỉ số thanh khoản) lại xuất hiện trong nhóm làm tăng nguy cơ (odds ratio 1,451) — trái với trực giác tài chính thông thường (thanh khoản cao hơn thường được kỳ vọng làm giảm rủi ro). Thứ hai và đáng chú ý hơn, hệ số của total_liabilities_lag1 mang dấu âm rất lớn (odds ratio chỉ 0,076, tức được diễn giải là làm giảm mạnh nguy cơ) — cũng trái ngược trực giác vì nợ phải trả nhiều hơn thường không nên làm giảm rủi ro kiệt quệ.

Đây là dấu hiệu điển hình của đa cộng tuyến: total_liabilities_lag1 tương quan rất cao với current_liabilities_lag1 và total_assets_lag1 ($|r| > 0,9$, xem Bảng 3.5), khiến Logistic Regression "chia sẻ" ảnh hưởng thật giữa các biến tương quan và có thể đổi dấu một biến để bù trừ cho biến còn lại — hệ số riêng lẻ khi đó không còn phản ánh đúng quan hệ nhân quả. Vì vậy, odds ratio trong nghiên cứu này cần được diễn giải theo nhóm biến có tương quan cao (đòn bẩy — nợ ngắn hạn — quy mô) thay vì theo từng hệ số đơn lẻ, và kết quả phản ánh mối liên hệ dự báo với rủi ro tài chính hơn là khẳng định quan hệ nhân quả tuyệt đối.

5.4. Phân tích Confusion Matrix của mô hình XGBoost



Để đánh giá chi tiết khả năng phân loại của mô hình, nghiên cứu sử dụng Confusion Matrix so sánh kết quả dự báo của mô hình XGBoost tại ngưỡng mặc định (0,5) và ngưỡng tối ưu theo F1-score, tập Test gồm 1.034 quan sát với khoảng 133 doanh nghiệp thực sự kiệt quệ (tỷ lệ dương 12,9%). Dựa trên Recall (0,647), Precision (0,465) và Accuracy (0,857) đã báo cáo, có thể suy ra ma trận nhầm lẫn tương ứng như sau:

Bảng 0.13: Ma trận nhầm lẫn ước tính — XGBoost tại ngưỡng tối ưu F1 (0,507)

Trường hợp	Số lượng (ước tính)
True Negative (đúng, không kiệt quệ)	≈ 802
False Positive (cảnh báo giả)	≈ 99
True Positive (đúng, bắt được kiệt quệ)	≈ 86
False Negative (bỏ sót)	47

Mô hình bỏ sót 47 doanh nghiệp thực sự rơi vào kiệt quệ tài chính (False Negative) tại cả ngưỡng mặc định lẫn ngưỡng tối ưu F1 — số lượng bỏ sót không thay đổi giữa hai ngưỡng do chúng khá gần nhau (mục 5.2). Kết hợp với kết quả Permutation Importance (mục 5.1) cho thấy mô hình phụ thuộc rất nhiều vào tín hiệu đòn bẩy (DebtToAssets_lag1), có thể suy luận rằng các trường hợp bị bỏ sót nhiều khả năng là những doanh nghiệp kiệt quệ nhưng chưa bộc lộ mức đòn bẩy đủ cao tại thời điểm dự báo ($t-1$) — ví dụ do suy giảm doanh thu, mất động lực tăng trưởng hoặc suy yếu lợi nhuận kéo dài mà chưa đi kèm áp lực nợ lớn. Đây là hạn chế quan trọng cần lưu ý khi ứng dụng mô hình, và gợi ý hướng cải thiện bằng cách bổ sung các đặc trưng phản ánh xu hướng tài chính dài hạn (tốc độ thay đổi ROA, doanh thu, dòng tiền qua nhiều năm) thay vì chỉ dùng chỉ tiêu tại một thời điểm $t-1$.

Confusion Matrix — XGBoost (tập Test)



Hình 0.7: Confusion Matrix – XGBoost (ngưỡng mặc định vs tối ưu F1)

5.5. Hàm ý quản trị

Kết quả nghiên cứu cho thấy Machine Learning có tiềm năng trở thành công cụ hỗ trợ hiệu quả trong việc xây dựng hệ thống cảnh báo sớm rủi ro tài chính. Đối với ngân hàng, mô hình có thể được tích hợp vào quy trình thẩm định tín dụng nhằm sàng lọc khách hàng doanh nghiệp, hỗ trợ đánh giá xác suất rủi ro trước khi cấp tín dụng hoặc trong quá trình giám sát sau giải ngân — trong đó tỷ lệ nợ trên tổng tài sản (DebtToAssets) nên được theo dõi như một chỉ báo hàng đầu. Đối với nhà đầu tư, mô hình cung cấp một chỉ báo bổ sung giúp nhận diện các doanh nghiệp có dấu hiệu suy giảm sức khỏe tài chính, hỗ trợ quản trị danh mục đầu tư. Đối với doanh nghiệp, kết quả phân tích các biến quan trọng có thể được sử dụng như một công cụ tự đánh giá sức khỏe tài chính, giúp ban lãnh đạo phát hiện sớm các dấu hiệu bất thường và triển khai các biện pháp cải thiện trước khi tình trạng kiệt quệ xảy ra.

6. KẾT LUẬN, HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết luận

Nghiên cứu đã xây dựng và đánh giá hệ thống mô hình học máy nhằm dự báo rủi ro kiệt quệ tài chính của 533 doanh nghiệp niêm yết Việt Nam giai đoạn 2020–2025, dựa trên dữ liệu tài chính dạng bảng (panel data). Đóng góp quan trọng nhất của nghiên cứu là thiết kế bài toán theo hướng dự báo lệch một kỳ ($t-1 \rightarrow t$) và kiểm soát nghiêm ngặt hiện tượng rò rỉ dữ liệu (data leakage) bằng thực nghiệm định lượng, thay vì chỉ loại bỏ các biến "nhìn có vẻ liên quan" đến nhãn.

Kết quả cho thấy sau khi loại bỏ các biến có khả năng tiết lộ trực tiếp nhãn và xây dựng quy trình đánh giá phù hợp, hiệu suất mô hình đạt mức AUC-ROC thực chất khoảng 0,79–0,87, thấp hơn đáng kể so với mức AUC-ROC gần như tuyệt đối (0,99–1,00) trong thử nghiệm dự báo cùng kỳ ban đầu. Sự khác biệt này khẳng định rằng kết quả ban đầu có hiệu suất quá cao chủ yếu đến từ việc mô hình tiếp cận các thông tin liên quan trực tiếp đến thời điểm xảy ra rủi ro, chứ không phản ánh khả năng dự báo thực sự.

Trong số bảy mô hình được thử nghiệm, nhóm dẫn đầu gồm Random Forest, Logistic Regression, SVM (RBF) và XGBoost đạt AUC-ROC trong khoảng 0,8530 - 0,8690 - cao và tương đối đồng đều, cho thấy phần lớn tín hiệu dự báo là các quan hệ mà cả mô hình tuyến tính lẫn phi tuyến đều nắm bắt được. Random Forest đạt AUC-ROC cao nhất (0,8690); Logistic Regression đạt AUC-PR cao nhất (0,4450) - chỉ số phù hợp hơn với dữ liệu mất cân bằng; XGBoost đạt F1-score cao nhất (0,5375). Kết quả kiểm định GroupKFold (AUC-ROC trung bình 0,8377, độ lệch chuẩn 0,0246) xác nhận mô hình có tính ổn định qua các nhóm doanh nghiệp khác nhau, không chỉ ghi nhớ đặc điểm riêng của một số mã cổ phiếu trong tập huấn luyện.

Ngược lại, KNN, Naive Bayes và Decision Tree đơn có hiệu suất thấp hơn rõ rệt. Đặc biệt, KNN đạt Accuracy rất cao (0,8267) nhưng Recall chỉ 0,0075 - gần như không phát hiện được doanh nghiệp rủi ro, minh chứng rõ ràng rằng Accuracy không phải là tiêu chí phù hợp để đánh giá mô hình trong bài toán mất cân bằng lớp; cần ưu tiên AUC-PR, Recall và F1-score.

Phân tích Permutation Importance cho thấy tỷ lệ nợ trên tổng tài sản (DebtToAssets_lag1) là đặc trưng dự báo mạnh nhất, chi phối gần như tuyệt đối so với các biến còn lại (ROA, thanh khoản, lợi nhuận giữ lại...). Phân tích Odds Ratio của Logistic Regression xác nhận đòn bẩy tài chính và cấu trúc nợ ngắn hạn làm gia tăng nguy cơ kiệt quệ rõ rệt nhất, trong khi khả năng sinh lời (ROA, biên lợi nhuận gộp) và doanh thu làm giảm

nguy cơ — phù hợp với lý thuyết tài chính doanh nghiệp kinh điển. Tuy nhiên, hiện tượng đa cộng tuyến giữa các biến quy mô/nợ khiến một số hệ số riêng lẻ (ví dụ `total_liabilities_lag1`) đổi dấu so với kỳ vọng lý thuyết, đòi hỏi phải diễn giải theo nhóm biến thay vì từng hệ số đơn lẻ.

Phân tích sai số cho thấy mô hình bỏ sót 47 trong khoảng 133 doanh nghiệp thực sự kiệt quệ trên tập Test ($\text{Recall} \approx 0,647$), và việc mô hình phụ thuộc nhiều vào tín hiệu đòn bẩy có thể khiến các trường hợp kiệt quệ xuất phát từ nguyên nhân khác (suy giảm doanh thu, mất hiệu quả hoạt động) dễ bị bỏ sót hơn. Nhìn chung, nghiên cứu khẳng định rằng việc kiểm toán rò rỉ dữ liệu bằng thực nghiệm là bước bắt buộc trong các bài toán dự báo tài chính: các biến "tưởng như an toàn" vẫn có thể vô tình tái tạo gần như hoàn hảo một nhãn được xây dựng từ luật ngưỡng cùng kỳ nếu không được xử lý đúng cách.

6.2. Hạn chế của nghiên cứu

Mặc dù đạt được các kết quả khả quan, nghiên cứu vẫn tồn tại một số hạn chế cần được xem xét.

Thứ nhất, biến mục tiêu trong nghiên cứu được xây dựng dựa trên quy tắc phân loại tài chính (rule-based) biến `label_distress` được xây dựng từ ngưỡng của bốn chỉ tiêu tài chính, không phải từ các sự kiện kiệt quệ thực tế đã xảy ra (phá sản, mất khả năng thanh toán, hủy niêm yết, tái cấu trúc nợ). Nhãn hiện tại phản ánh mức độ suy yếu tài chính theo tiêu chí định trước nhưng chưa hoàn toàn đại diện cho mọi trường hợp khủng hoảng thực tế.

Thứ hai, số lượng quan sát thuộc nhóm rủi ro còn tương đối hạn chế, chỉ khoảng 373 quan sát dương ($14,7\% \times 2.538$) trong toàn bộ dữ liệu panel. Điều này có thể làm giảm khả năng học các mẫu phức tạp của mô hình và làm tăng độ biến động trong quá trình đánh giá, đặc biệt đối với các thuật toán có nhiều tham số.

Thứ ba, hiện tượng đa cộng tuyến giữa các biến tài chính: một số biến phản ánh quy mô và cấu trúc vốn như Total Assets, Total Liabilities, Current Liabilities và Debt-to-Assets có hệ số tương quan rất cao ($|r| > 0,9$). Điều này có thể làm cho hệ số ước lượng của Logistic Regression thay đổi dấu hoặc không còn phản ánh đúng tác động riêng lẻ của từng biến. Vì vậy, kết quả cần được diễn giải theo nhóm biến thay vì dựa trên từng hệ số riêng biệt.

Cuối cùng, nghiên cứu chủ yếu sử dụng các chỉ tiêu tài chính nội tại của doanh nghiệp và chưa xem xét các yếu tố bên ngoài như chu kỳ kinh tế, lãi suất, tăng trưởng GDP, biến động thị trường hoặc đặc điểm ngành nghề. Đồng thời, kết quả phân tích Permutation Importance cho thấy mô hình phụ thuộc tương đối nhiều vào biến `DebtToAssets_lag1`, phản

ánh vai trò nổi bật của đòn bẩy tài chính trong việc dự báo nguy cơ kiệt quệ. Điều này có thể làm giảm khả năng nhận diện các trường hợp kiệt quệ phát sinh từ những nguyên nhân khác như suy giảm dòng tiền, hiệu quả hoạt động hoặc các yếu tố kinh tế vĩ mô và đặc thù ngành chưa được đưa vào mô hình.

6.3. Hướng phát triển trong tương lai

Từ những hạn chế trên, một số hướng phát triển có thể được đề xuất nhằm nâng cao khả năng dự báo và tính ứng dụng của mô hình.

Thứ nhất, nghiên cứu có thể mở rộng khoảng thời gian dự báo bằng cách thử nghiệm các độ trễ dài hơn như $t-2$ hoặc $t-3$, qua đó đánh giá khả năng cảnh báo sớm hơn trước khi doanh nghiệp rơi vào tình trạng kiệt quệ tài chính.

Thứ hai, bộ dữ liệu cần được bổ sung các biến phản ánh môi trường kinh tế vĩ mô và đặc điểm ngành, chẳng hạn như tăng trưởng GDP, lãi suất, lạm phát, biến động thị trường hoặc lĩnh vực hoạt động của doanh nghiệp. Việc kết hợp các yếu tố nội tại và bên ngoài sẽ giúp mô hình phản ánh đầy đủ hơn các nguyên nhân dẫn đến rủi ro tài chính.

Thứ ba, nghiên cứu có thể khai thác thêm các đặc trưng theo chuỗi thời gian, như tốc độ thay đổi của doanh thu, lợi nhuận, ROA hoặc dòng tiền qua nhiều năm, nhằm cải thiện khả năng phát hiện các doanh nghiệp suy yếu dần nhưng chưa bộc lộ rõ dấu hiệu rủi ro tại thời điểm dự báo.

Cuối cùng, nếu có thể thu thập dữ liệu về các sự kiện kiệt quệ thực tế như phá sản, mất khả năng thanh toán, hủy niêm yết hoặc tái cấu trúc nợ, mô hình nên được kiểm chứng trên bộ dữ liệu này để đánh giá khả năng khái quát hóa và khắc phục hạn chế của phương pháp gán nhãn dựa trên quy tắc.

Tổng thể, nghiên cứu cho thấy các mô hình học máy có tiềm năng hỗ trợ hiệu quả việc xây dựng hệ thống cảnh báo sớm rủi ro tài chính doanh nghiệp khi được xây dựng trên quy trình xử lý dữ liệu hợp lý, kiểm soát hiện tượng data leakage và đánh giá bằng các chỉ tiêu phù hợp với dữ liệu mất cân bằng. Trong tương lai, việc mở rộng nguồn dữ liệu, kết hợp các yếu tố kinh tế vĩ mô và hoàn thiện phương pháp xây dựng nhãn sẽ góp phần nâng cao độ chính xác cũng như tính ứng dụng của mô hình trong thực tiễn tại Việt Nam.

~HẾT~

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Anh

1. Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4), 589–609.
<https://doi.org/10.1111/j.1540-6261.1968.tb00843.x>
2. Beneish, M. D. (1999). The detection of earnings manipulation. *Financial Analysts Journal*, 55(5), 24–36. <https://doi.org/10.2469/faj.v55.n5.2296>
3. Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>
4. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery.
<https://doi.org/10.1145/2939672.2939785>
5. Dickinson, V. (2011). Cash flow patterns as a proxy for firm life cycle. *The Accounting Review*, 86(6), 1969–1994. <https://doi.org/10.2308/accr-10130> (Lưu ý: đây là năm công bố chính thức; bài viết cần thống nhất lại năm trích dẫn thành 2011 thay vì 1989.)
6. Ohlson, J. A. (1980). Financial ratios and the probabilistic prediction of bankruptcy. *Journal of Accounting Research*, 18(1), 109–131. <https://doi.org/10.2307/2490395>
7. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Nguồn dữ liệu

8. CafeF. (n.d.). *Dữ liệu tài chính doanh nghiệp niêm yết*. Truy xuất từ <https://cafef.vn/du-lieu>
9. Vietstock Finance. (n.d.). *Dữ liệu báo cáo tài chính doanh nghiệp niêm yết*. Truy xuất từ <https://finance.vietstock.vn>
10. VnEconomy. (2025). *Danh sách 96 mã chứng khoán bị cắt margin trên HOSE*. Truy xuất <https://vneconomy.vn/da-co-96-ma-bi-cat-margin-tren-hose.htm>

*** Link bài:

https://drive.google.com/drive/folders/1fLPtLwANvO4GBbeGhojqTuDr7_eE5UBG?usp=sharing